

준비 문서는 무엇을 예측했고, 실데이터는 무엇을 가르쳤나

조선일보 데이터셋과 HCX 인증키 수령 이후, 파이프라인 전 구간을 실데이터·실API로 관통시킨 기록

문서 번호	CLF-LOG-001 (v1.0)
기록 기간	2026-07-20 (데이터셋·HCX 키 수령 당일)
대상	조선일보 2025년 기사 2,706건 · KOSIS Open API · NCP HCX
산출	커밋 22건 · 규칙 카드 신규 3종 · 테스트 137→185건

1. 한 줄 요약

설계는 대체로 옳았고, 실데이터는 설계가 몰랐던 여섯 겹의 저항을 드러냈다. 그 여섯 겹을 벗기는 동안 오판은 5건에서 0건으로 줄었고, 매 겹마다 규칙 카드가 하나씩 남았다. 픽스처로는 단 하나도 발견할 수 없었던 문제들이다. 그리고 7차 실행에서 **실제 뉴스 기사를 실제 국가통계로 정확히 검증한 첫 판정 3건**이 나왔다.

첫 정확한 판정 (2026-07-20, 7차 실행)

주장: **"통계청은 5월 '1월 소비자물가 동향'에서 지난달 소비자물가가 작년 같은 달보다 2.2% 올랐다고 밝혔다."** (조선일보 2025-02-06)

판정: **● 일치** — KOSIS 소비자물가조사 > 월별 소비자물가 등락률(DT_1J22042), 2025-01 전년동월비 **2.2%**

근거: 반올림 자릿수 기준 일치 · 계산: 2.2% ≈ 2.2%

2. 준비 문서의 예측 vs 실측 결과

■ 적중한 예측

준비 문서가 말한 것	실측 결과
문서 19: 전수 인덱싱은 호출 예산상 불가능(28만 표 vs 1,000회). 통합 검색(경로 C)이 전수 커버리지를 얻는 유일하게 현실적인 길	그대로 맞았다. 경로 C 실검색이 성공했고, 인덱싱 없이 28만 표를 검색했다
소스분류 기획서: "경제면 기사 전체를 KOSIS로 바로 보내면 안 된다"	경제면 Claim 중 KOSIS 후보는 4.4%뿐 . 민간·시장자료(14.8%)가 3배 이상

준비 문서가 말한 것	실측 결과
소스분류 기획서: KOSIS_precision 최우선, 애매하면 UNKNOWN	이 원칙이 실제로 오판을 막았다. 반대로 이 원칙을 어긴 지점(해외 주장)에서 정확히 오판이 났다
문서 23: 골든셋 5축(고용·인구·가구·농가·물가)	실제 분포와 정렬 — KOSIS 후보 820건이 인구·가구 337, 고용 271, 물가 130, 농가 82로 분해됨
문서 25: 불일치는 무조건 사람 승인(HITL 발행규칙)	첫 실판정 5건이 전부 오'불일치'였다. 이 규칙이 없었다면 맞는 기사 5건을 틀렸다고 공표할 뻔했다
문서 19: 사실검증 합정 8종(잠정치·기준연도 등)	합정의 존재는 맞았고, 목록은 불완전했다 (§4 참조)

■ 빗나간 예측 — 가장 값진 배움

준비 문서가 믿은 것	실데이터가 말한 것
EXP-001: 하이브리드 검색 Hit@3 = 1.00	실 KOSIS에서는 무의미했다 . 로컬 픽스처는 토큰 OR 매칭이라 긴 문장 질의도 통했지만, 실 KOSIS 통합검색은 검색창처럼 짧은 키워드 를 기대한다. 문장형 질의 30건 중 27건이 `err30 데이터가 존재하지 않습니다`
데이터셋은 정제된 기사 본문일 것	크롤 페이지 전체가 담겨 있었다 — 사이트 메뉴·기자 프로필· 독자 댓글(100자평) ·광고 추천이 본문에 혼입
검색 1위 표를 쓰면 된다	1위가 주장에 맞는 표라는 보장이 없다. '소비자물가' 1위는 지역·연간표 였고, 정작 필요한 월별 전국 표는 4~7위에 묻혀 있었다
단위는 UNIT_NM 필드에 있다	KOSIS 등락률 표는 단위를 항목명 안에 넣는다(전년동월비(%)). UNIT_NM은 빈 문자열

3. 단계별 실측 기록

■ 3.1 데이터셋 EDA (문서 18)

항목	값
원본	2,706건 (2025년, 경제 섹션 90.5%)
레이블 규명	True 2,507 = 경제 검색분 / False 199 = 일반 기사
클리닝 후 적재	2,649건, 본문 중앙값 1,146자
주장 후보	16,464건 (기사당 6.2건)

클리닝이 잡은 사고 2건 — 둘 다 조용히 결과를 망칠 것들이었다:

1. 크롤 본문은 개행이 없는 한 줄이라, 기존 저작권 라인 필터가 **기사 전체를 삭제**하고 있었다(2,706건 중 630건만 생존).
2. 본문 뒤에 **독자 댓글**이 붙어 있었다 — 댓글 속 수치가 검증 대상으로 잡힐 뻔했다.

3.2 소스 분류 전수 적용 (문서 19)

기획서의 8라벨 체계를 16,464건 전수에 적용:

source_type	건수	비중
UNKNOWN	10,846	65.9%
PRIVATE_SOURCE	2,332	14.2%
OTHER_OFFICIAL	1,312	8.0%
FORECAST_OR_OPINION	1,127	6.8%
KOSIS 후보	820	5.0%
PLATFORM_SOURCE	27	0.2%

주목할 역전: 전체에서는 규모형이 54.5%지만, KOSIS 후보 안에서는 **증감형(425)이 규모형(284)을 앞선다**. 통계 지표는 "전년 대비 얼마나"로 기사화되기 때문 — 파생 계산과 %/%p 구분이 주 병목임이 데이터로 확인됐다.

3.3 클라우드 환경 구축 — 두 API의 위치가 갈렸다

환경	HGX	KOSIS
개발망(LG파워콤)	미확인	✗ 정부망 443 차단
GitHub Actions(해외 IP)	✓ (엔드포인트 수정 후)	⚠ 불안정 — 4회 중 1회만 도달
NCP 국내 서버	✓	✓ 안정

- **HGX 400 오류의 정체:** 구 엔드포인트(/testapp/v1/)를 쓰고 있었다. v3(/v3/chat-completions/{model}) + X-NCP-CLOVASTUDIO-REQUEST-ID 헤더로 해결.
- **결론:** HGX는 상용 API라 어디서든 도달하지만, **KOSIS는 정부망이라 국내 IP가 필요하다**. 추측이 아니라 실측으로 배포 위치가 정해졌다.

3.4 매핑 전략 전환 — 예산 97.6% 절감

실 API가 우리 설계를 뒤집었다. 문장형 긴 질의가 27/30 실패한 뒤 **지표어 단위 질의**로 전환:

항목	전환 전	전환 후
고유 검색어	795개	19개
필요 예산	795회	19회
검색어당 Claim	1.0	43.2
검색 성공률	3/30	19/19

부수적으로 발견한 오탐: 키워드 **어가**(어업가구)가 "**들어가**", "**이어가기로**"에 **부분일치**해 62건을 잘못 잡고 있었다.
고령 → "최고령 희생자"(항공참사) 오탐도 같은 유형.

4. 첫 실 판정 — 오판 5건에서 시작한 플라이휠

파이프라인 전 구간(실 기사 → 실 검색 → 실 값 조회 → 결정적 판정)을 관통시킨 결과, **5건 전부 오'불일치'**였다. 사실검증에서 틀린 '불일치'는 맞는 기사를 공개적으로 틀렸다고 하는 **최악의 오류**다. 그 5건이 규칙 카드의 원료가 됐다.

회차	오'불일치'	드러난 결함	남은 자산
1차	5	일본·미국 물가를 한국 통계와 대조	규칙 A2-0014 해외 주체 가드
2차	4	월간 주장을 연간 통계와 대조	규칙 A2-0015 시점 입도 가드
3차	1	검색 1위가 지역·연간표	리랭커 (rerank.py)
4차	1	시점 파싱·주기 고정·필터 절삭	배관 3종 수정
5차	4	전월비를 전년동월비로 오인	규칙 A2-0016 비교 기준 정합
6차	2	단위가 항목명에 있어 판정 포기	단위 유추 + 기준 기본값
7차	0	—	일치 3 · 불일치 1 · 판단불가 6

7차 결과의 내역: **일치 3건**(소비자물가 월간 상승률 — 전부 기사가 정확했고 시스템이 그것을 확인), **불일치 1건**(모집단 유형 — §7 미해결), **판단불가 6건**(해외 주장 5 + 지수 기준연도 표기 1 — 전부 회피가 타당한 사례). 오'불일치'는 5건에서 **0건**이 됐다.

준비 문서의 함정 목록이 불완전했음이 드러났다. 문서 19가 예측한 함정(잠정치·기준연도·이중계상)은 맞았지만, 실 데이터는 세 가지를 더 가르쳤다 — **해외 주체 혼입**, **시점 입도 불일치**, **비교 기준(항목) 불일치**. 셋 다 픽스처에는 존재할 수 없는 문제였다.

5. 숫자로 보는 결과

지표	값
처리한 실 기사	2,649건
추출한 주장 후보	16,464건
KOSIS 검증 후보	820건
실 KOSIS 검색 성공	19/19 질의
정확한 실 판정	일치 3건 (오'불일치' 5 → 0)
신규 규칙 카드	3종 (A2-0014-0015-0016) → 총 15종
테스트	137 → 185건
커밋	22건
KOSIS 호출 예산	1,000회 중 약 65회 사용 (935회 잔량)

6. 이 기록이 증명하는 것

① 테스트·Mock은 목적지가 아니지만, 실전으로 갈 때 돈과 시간을 아끼는 안전벨트다.

dry-run이 예산을 한 푼도 쓰지 않고 쓰레기 질의를 먼저 보여줬고, 30건 소량 배치가 795회를 지르기 전에 전략 오류를 잡았다. 검증 없이 전량 실행했다면 예산의 80%를 날렸을 것이다.

② HITL 발행규칙은 장식이 아니었다.

첫 실판정 5건의 오'불일치'는 "불일치는 무조건 사람 승인" 규칙 덕분에 자동 발행되지 않았을 것이다. 설계가 최악의 사고를 막았다.

③ "실패 1건 = 자산 1줄"이 실제로 돌아왔다.

오판 5건이 규칙 카드 3종과 리랭커로 전환됐고, 각 카드에는 유래 사례가 그대로 기록돼 있다. 같은 실패를 두 번 하지 않는 구조가 실데이터에서 작동했다.

7. 남은 과제

- **모집단 정렬**: "175개 품목 평균"(부분집합)을 전체 CPI와 대조하는 문제 — 규칙 A2-0017 후보. 7차에서 유일하게 남은 오'불일치'
- **지수 기준연도 표기 오판상**: "소비자물가지수는 115.71(2020년=100)"에서 기준연도 표기를 주장 시점으로 읽어 2020년 자료를 찾는다 — 판단불가로 안전하게 빠지지만 사유가 틀렸다
- **매핑 적합성 확대**: 리랭커는 물가 계열에서 검증됐고, 나머지 지표(취업자·출생아·인구)로 확대 필요
- **판정률 회복**: 가드를 쌓아 오판은 막았으나 판단불가 비중이 높다. 정직한 회피는 좋은 기본값이지 최종 목표가 아니다
- **HCX 2차 판별 실연동**: `detect_llm.py`는 구현·배선됐으나 실 HCX 카세트 녹화가 남아 있다

본 기록의 모든 수치는 2026-07-20 실행 로그에서 인용했으며, 재현 명령과 커밋 해시가 저장소에 남아 있다. 진행 중인 항목은 진행 중으로 표기했다.